钱泽凯 Zekai Qian



博士四年级在读 · 哈尔滨工业大学 · 预计 2027 至 2028 年毕业

海量数据计算研究中心 大数据计算黑龙江省重点实验室 数据质量评估与修复国家工程研究中心

年龄：25 岁 · 电话：13579810745 · 邮箱：qzk010728@gmail.com · 博士导师：**王宏志 教授**

研究方向：数据中心 AI（Data-centric AI）· 按需数据准备与数据清洗 · 数据质量评估与提升 · 数据模型联合优化

🏠 主页：https://qzkinhit.github.io/ · 🎓 Google Scholar · 📝 OpenReview · 💻 GitHub: qzkinhit

教育背景

2023–至今 哈尔滨工业大学 · 计算机科学与技术 · 硕博连读　海量数据计算研究中心　研究生特等奖学金（连续两年）

2019–2023 哈尔滨工业大学 · 计算机科学与技术 · 学士　专业学分绩排名 3/91 · 省优秀毕业生

代表性论文

面向模型的按需数据准备与数据模型联合调优

ICML 2026 CCF A 学生一作 DMCO: Budget-Aware Co-Optimization of Data Cleaning and AutoML | X. Ding（副导师）, **Z. Qian**, S. Chen, H. Hu, C. Wang, H. Wang, J. Wang

VLDB Workshop 2026 CCF A Workshop 一作 Oral Paper Award DemandPrep: Demand-Driven Data Preparation via Agentic Action Allocation and Operator-Grounded Execution | **Z. Qian**, X. Ding, H. Wang, C. Wang

VLDB 2025 CCF A 一作 DemandClean: A Multi-Objective Learning Framework for Balancing Model Tolerance to Data Authenticity and Diversity | **Z. Qian**, X. Ding, C. Wang, H. Wang

大规模分布式数据质量提升流水线与工业时序数据质量评估（电网、华为云企业落地）

VLDB 2025 CCF A 学生一作 Oral UniClean: A Scalable Data Cleaning Solution for Mixed Errors based on Unified Cleaners and Optimized Cleaning Workflow | X. Ding（副导师）, **Z. Qian**, H. Wang, S. Chen, Y. Tang, H. Su, H. Hu, C. Wang

ICDE 2025 CCF A 学生一作 UniClean: A Multi-Signal Fusion Pipeline for Optimizing Data Cleaning Workflow | X. Ding（副导师）, **Z. Qian**, H. Wang, Z. Sun, S. Chen, H. Su, H. Hu

计算机科学 2024 CCF B 一作 封面文章 面向多样化数据清洗任务的证据集智能选择方法（Evidence Set Selection for Diverse Data Cleaning Tasks） | **Z. Qian**, X. Ding, Z. Sun, H. Wang, Y. Zhang

ICDE 2025 CCF A Oral tDCDiscover: Mining Threshold Denial Constraints from Time Series Data | X. Ding, M. Zhou, Y. Liu, **Z. Qian**, C. Wang, H. Wang, J. Wang

在投论文（多模态数据准备、工业时序分析与数据中心 AI）

ICDE 2027 在投 CCF A 一作 DemandClean: Task-Driven Operation Selection for Data Cleaning with Constrained Ground-Truth

VLDB 2027 在投 CCF A 一作 OmniSelect: Quality-Aware Data Selection via Task-Driven Strategy Adjudication

ICLR 2027 在投 CCF A 一作 CARVEPrep: Model-Aware Data Preparation for Tabular Foundation Model Post-Training

TII 在投 一区 Top IF 11.7 学生一作 VioExplain: Single-Event Knowledge Explains Concurrent Violations in Industrial Time Series

项目经历

大规模数据质量提升流水线

2023–2025 课题负责人　华为合作项目

技术：面向以数据为中心的 AI，将行分布、列规则与外部知识三类清洗信号统一为 73 种清洗器，按属性关联分块并行，以核心集抽取与贡献溯源迭代编排清洗顺序，使清洗器排序搜索由错误数的阶乘级降为多项式级，为下游分析与模型训练提供高质量数据。

验收指标：F1 较 SOTA 平均提升 20%；支撑亿级生产数据小时级清洗，千万行 < 1 小时（32 核 CPU 集群）。

成果：华为云发明专利**已公开**（CN120973774A，学生第一发明人）；系统部署于**华为云 DLI 生产环境**，完成亿级生产数据验证。

论文：UniClean · 混合错误清洗（VLDB 2025，Oral）及多信号融合流水线（ICDE 2025），学生一作。

面向数据智能的大数据质量评估与提升关键技术研究

2024–至今 学生主要参与　黑龙江省自然科学基金

任务：研究任务驱动的质量评估与按需数据准备，对齐分类、回归、预测及多模态基础模型训练的数据需求。

技术：以下游模型效用为准则准备数据，多目标学习刻画模型对真实性与多样性的容忍度，两阶段 Dueling Double DQN 在标注预算下为每个错误单元格选择不动、修复、删除或估计替换，仅查询至多 6.5% 单元格的真值，Agent 依据下游验证编排准备动作与算子执行。

专利：发明专利《一种基于成本以及分析模型的数据清洗方法、设备以及存储介质》**已授权**（CN121636481B，第一发明人）。

论文：DemandClean · 多目标学习（VLDB 2025）；DemandClean · 操作选择（ICDE 2027 在投）；DemandPrep · Agent 数据准备（VLDB Workshop 2026，**Oral Paper Award**），均为一作。

工业时序数据高鲁棒查询处理技术

2021–2024 项目骨干　国家重点研发计划“工业软件”重点专项 · 2021YFB3300502

技术：构建覆盖质量评估、多类型错误检测与多维修复的工业时序数据技术栈，为时序预测与异常检测提供高质量数据。

应用：研发部署 tDCDiscover 等算法；参与国家电网科技项目，以分层重构神经网络检测电力时序异常，落地国网治理工具。

论文：证据集智能选择（CCF BigData 2023 **最佳学生论文**，一作；《计算机科学》2024 封面文章）；tDCDiscover（ICDE 2025，Oral）。

《大数据质量》教材

2025–2026 学生骨干（排名第一）　“十四五”国家级规划教材 · 大数据新兴领域，全领域仅十本

执笔：第 1、3、6 章（数据质量概述、劣质数据分类、数据清洗系统及工具），高等教育出版社 2025 年 12 月出版，王宏志教授主编。

获奖情况

2022 第十五届全国大学生信息安全竞赛 (作品赛)，全国一等奖 (队长，第一贡献)，作品：基于 MAE 人脸隐私保护方法的身份认证系统

2023 CCF BigData 2023 最佳学生论文（第一作者，本届大会唯一）　**2024** 《计算机科学》封面文章（2024 年 8 月，51(8)）

学生工作

2023–2024 2019 级本科生党支部副书记　**2025–至今** 师生联合党支部委员　**2024–至今** CCF 哈工大学生分会执委 · CCF 专业会员