

钱泽凯 Zekai Qian

博士在读 · 哈尔滨工业大学 · 海量数据计算研究中心

出生年月: 2001 年 7 月 · 电话: 13579810745 · 邮箱: qzk010728@gmail.com · 博士生导师: 王宏志 教授

研究方向: 数据中心 AI (Data-centric AI) · 按需数据准备与数据清洗 · 面向大模型与机器学习的数据质量 · Agent 驱动的数据系统 · 分布式大数据质量管理

 <https://qzkinhit.github.io/> ·  Google Scholar ·  OpenReview ·  GitHub: qzkinhit



教育背景

- 2023 - 至今 哈尔滨工业大学 · 计算机科学 · 硕博连读 (博士三年级在读, 预计 2028 年毕业) 海量数据计算研究中心
- 2019 - 2023 哈尔滨工业大学 · 计算机科学 · 学士

代表性论文

面向模型的按需数据准备

ICML 2026   DMCO: Budget-Aware Co-Optimization of Data Cleaning and AutoML | X. Ding (副导师), Z. Qian, S. Chen, H. Hu, C. Wang, H. Wang, J. Wang

VLDB Workshop 2026   DemandPrep: Demand-Driven Data Preparation via Agentic Action Allocation and Operator-Grounded Execution | Z. Qian, X. Ding, H. Wang, C. Wang

VLDB 2025   DemandClean: A Multi-Objective Learning Framework for Balancing Model Tolerance to Data Authenticity and Diversity | Z. Qian, X. Ding, C. Wang, H. Wang

大规模、多模态数据质量管理体系与流水线 (电网, 华为云企业落地)

VLDB 2025    UniClean: A Scalable Data Cleaning Solution for Mixed Errors based on Unified Cleaners and Optimized Cleaning Workflow | X. Ding (副导师), Z. Qian, H. Wang, S. Chen, Y. Tang, H. Su, H. Hu, C. Wang

ICDE 2025   UniClean: A Multi-Signal Fusion Pipeline for Optimizing Data Cleaning Workflow | X. Ding (副导师), Z. Qian, H. Wang, Z. Sun, S. Chen, H. Su, H. Hu

计算机科学 2024    面向多样化数据清洗任务的证据集智能选择方法 (Evidence Set Selection for Diverse Data Cleaning Tasks) | Z. Qian, X. Ding, Z. Sun, H. Wang, Y. Zhang

ICDE 2025  CBAClean: A Comprehensive System for Recommending Data Cleaning Solutions Through Cost-Benefit Analysis in Data Quality Management | X. Ding (副导师), H. Su, Z. Qian, W. Cui, S. Chen, Z. Liang, C. Wang, H. Wang

ICDE 2025  tDCDiscover: Mining Threshold Denial Constraints from Time Series Data | X. Ding, M. Zhou, Y. Liu, Z. Qian, C. Wang, H. Wang, J. Wang

数据资产评估与治理 (综述)

BDMA 2025  A Survey on Data Asset Value Change Estimation and Appreciation with Data Governance | X. Ding, G. Li, Y. Tang, C. Liang, T. Yu, M. Zhou, Y. Liu, Z. Qian, Z. Song, et al.

在投论文

SIGMOD 2027 在投   DemandClean: Task-Driven Operation Selection for Data Cleaning with Constrained Ground-Truth | Z. Qian, X. Ding, Z. Zhao, S. Chen, C. Wang, H. Wang

项目经历

2023 - 2025   大数据质量提升流水线

面向生产数据多类错误混杂、亿级规模数据质量管理困难的问题, 构建基于算子关联分块、核心集抽取与贡献溯源迭代编排的端到端自动清洗流水线, 为下游分析与模型训练提供可扩展、自动化、可解释的高质量数据底座;

F1 较 SOTA 系统平均提升 20%, 支撑华为云亿级生产数据小时级清洗 (千万行 < 1 小时, 32 核 CPU 集群);

产出: 华为发明专利 1 项; 系统部署于华为云 DLI 生产环境, 完成亿级生产数据验证落地。

论文 UniClean · 可扩展混合错误清洗 (VLDB, Oral, 二作 · 学生一作) · UniClean · 多信号融合流水线 (ICDE 2025, 二作 · 学生一作)

2024 - 至今   面向数据智能的大数据质量评估与提升关键技术研究

围绕“数据为模型服务”主线, 研究任务驱动的数据质量评估与按需数据准备, 将数据准备与下游任务 (分类、回归、预测, 及多模态基础模型训练数据的质量管理) 的真实需求对齐;

技术路线: 多目标学习平衡数据真实性与多样性 → 将操作选择建模为成本约束序贯决策、以强化学习 Dueling Double DQN 求解 → 用 Agent 自主编排数据准备动作与算子执行。

论文 DemandClean · 多目标学习 (VLDB, 一作) · DemandClean · 任务驱动操作选择 (SIGMOD 在投, 一作) · DemandPrep · Agent 数据准备 (VLDB Workshop 2026, Oral, 一作)

2021 - 2024   工业时序数据高鲁棒查询处理技术 “工业软件”重点专项, 2021YFB3300502

面向工业时序数据构建“画一检一修”质量技术栈 (评估、多类型错误检测、多维修复), 为下游时序预测与异常检测模型提供高质量数据; 研发部署 tDCDiscover 等算法, 参与国家电网科技项目 (分层重构神经网络的电力时序异常检测, 落地电网治理工具)。

论文 证据集智能选择 (CCF BigData 2023 最佳学生论文, 一作; 《计算机科学》2024 封面文章) · tDCDiscover (ICDE 2025)

2025 - 2026   《大数据质量》—— 大数据新兴领域国家级规划教材, 全领域仅十本

获奖情况

2022 第十五届全国大学生信息安全竞赛 (作品赛) — 全国一等奖 (队长, 第一贡献), 作品: 基于 MAE 人脸隐私保护方法的身份认证系统

2023 CCF BigData 2023 最佳学生论文 (第一作者, 本届大会唯一) 2024 《计算机科学》封面文章 (2024 年 8 月, 51(8))

2023 全国大学生计算机系统能力大赛 (黑龙江省第三名, 入围全国决赛) 2023 & 2024 省优秀毕业生, 研究生特等奖学金 (连续两年)

学生工作

2023 - 2024 2019 级本科生第六党支部副书记 2025 - 至今 实验室师生联合党支部宣传委员

2024 - 至今 CCF 哈工大学生分会执委 · CCF 专业会员