

钱泽凯 Zekai Qian

博士在读 · 哈尔滨工业大学 · 海量数据计算研究中心

出生年月：2001 年 7 月 · 电话：13579810745 · 邮箱：qzk010728@gmail.com · 博士导师：王宏志 教授

研究方向：数据中心 AI (Data-centric AI) · 按需数据准备与数据清洗 · 面向大模型与机器学习的数据质量 · 数据模型联合优化

🏠 主页：https://qzkinhit.github.io/ · 🎓 Google Scholar · 📝 OpenReview · 🐙 GitHub: qzkinhit



教育背景

2023-至今 哈尔滨工业大学 · 计算机科学 · 硕博连读 (博士三年级在读, 预计 2028 年毕业) 海量数据计算研究中心

2019-2023 哈尔滨工业大学 · 计算机科学 · 学士

代表性论文

面向模型的按需数据准备与数据模型联合调优

ICML 2026 **CCF A** **学生一作** Research Paper DMCO: Budget-Aware Co-Optimization of Data Cleaning and AutoML | X. Ding (副导师), **Z. Qian**, S. Chen, H. Hu, C. Wang, H. Wang, J. Wang

VLDB Workshop 2026 **CCF A Workshop** **Oral Paper Award** **一作** Research Paper DemandPrep: Demand-Driven Data Preparation via Agentic Action Allocation and Operator-Grounded Execution | **Z. Qian**, X. Ding, H. Wang, C. Wang

VLDB 2025 **CCF A** **一作** Research Paper DemandClean: A Multi-Objective Learning Framework for Balancing Model Tolerance to Data Authenticity and Diversity | **Z. Qian**, X. Ding, C. Wang, H. Wang

大规模、多模态数据质量管理体系与流水线 (电网, 华为云企业落地)

VLDB 2025 **CCF A** **Oral** **学生一作** Research Paper UniClean: A Scalable Data Cleaning Solution for Mixed Errors based on Unified Cleaners and Optimized Cleaning Workflow | X. Ding (副导师), **Z. Qian**, H. Wang, S. Chen, Y. Tang, H. Su, H. Hu, C. Wang

ICDE 2025 **CCF A** **学生一作** Demo Paper UniClean: A Multi-Signal Fusion Pipeline for Optimizing Data Cleaning Workflow | X. Ding (副导师), **Z. Qian**, H. Wang, Z. Sun, S. Chen, H. Su, H. Hu

计算机科学 2024 **CCF B** **一作** **封面文章** 面向多样化数据清洗任务的证据集智能选择方法 (Evidence Set Selection for Diverse Data Cleaning Tasks) | **Z. Qian**, X. Ding, Z. Sun, H. Wang, Y. Zhang

ICDE 2025 **CCF A** Research Paper **Oral** tDCDiscover: Mining Threshold Denial Constraints from Time Series Data | X. Ding, M. Zhou, Y. Liu, **Z. Qian**, C. Wang, H. Wang, J. Wang

在投论文 (多模态数据准备: 表格、时序、文本等; 数据中心的 AI)

VLDB 2027 在投 **CCF A** **一作** Research Paper DemandClean: Task-Driven Operation Selection for Data Cleaning with Constrained Ground-Truth | **Z. Qian**, X. Ding, Z. Zhao, S. Chen, C. Wang, H. Wang

AAAI 2027 在投 **CCF A** **一作** Research Paper OmniSelect: Adaptive Data Selection with Complementary Quality Signals for Modality-Specific Foundation Models | **Z. Qian**, X. Ding, Y. Tang, S. Cheng, C. Zhao, H. Wang, C. Wang

ICLR 2027 在投 **一作** Research Paper CARVEPrep: Evidence-Guided Action-Space Search for Foundation Model Post-Training | **Z. Qian**, X. Ding, H. Wang, C. Wang

项目经历

大数据质量提升流水线

2023-2025 **课题负责人** 华为云合作项目

技术: 面向亿级生产数据的多类混合错误, 基于算子关联分块、核心集抽取与贡献溯源迭代编排, 构建可扩展、自动化、可解释的端到端清洗流水线, 服务下游分析与模型训练。

验收指标: **F1 较 SOTA 平均提升 20%**; 支撑亿级生产数据小时级清洗, 千万行 < 1 小时 (32 核 CPU 集群)。

成果: 华为发明专利 **1 项**; 系统部署于华为云 **DLI 生产环境**, 完成亿级生产数据验证。

论文: UniClean · 混合错误清洗 (VLDB 2025, Oral) 及多信号融合流水线 (ICDE 2025), 学生一作。

面向数据智能的大数据质量评估与提升关键技术研究

2024-至今 **学生主要参与** 黑龙江省自然科学基金

任务: 研究任务驱动的质量评估与按需数据准备, 对齐分类、回归、预测及多模态基础模型训练的数据需求。

技术: 多目标学习平衡真实性与多样性; Dueling Double DQN 求解成本约束的操作选择序贯决策; Agent 自主编排数据准备动作与算子执行。

论文: DemandClean · 多目标学习 (VLDB 2025); DemandClean · 操作选择 (VLDB 2027 在投); DemandPrep · Agent 数据准备 (VLDB Workshop 2026, **Oral Paper Award**), 均为一作。

工业时序数据高鲁棒查询处理技术

2021-2024 **项目骨干** 国家重点研发计划“工业软件”重点专项 · 2021YFB3300502

技术: 构建覆盖质量评估、多类型错误检测与多维修修的工业时序数据技术栈, 为时序预测与异常检测提供高质量数据。

应用: 研发部署 tDCDiscover 等算法; 参与国家电网科技项目, 以分层重神经网络检测电力时序异常, 落地国网治理工具。

论文: 证据集智能选择 (CCF BigData 2023 **最佳学生论文**, 一作; 《计算机科学》2024 封面文章); tDCDiscover (ICDE 2025, Oral)。

《大数据质量》教材

2025-2026 **学生骨干 (排名第一)** “十四五”国家级规划教材 · 大数据新兴领域, 全领域仅十本

获奖情况

2022 第十五届全国大学生信息安全竞赛 (作品赛) — 全国一等奖 (队长, 第一贡献), 作品: 基于 MAE 人脸隐私保护方法的身份认证系统

2023 CCF BigData 2023 最佳学生论文 (第一作者, 本届大会唯一) **2024** 《计算机科学》封面文章 (2024 年 8 月, 51(8))

2023 全国大学生计算机系统能力大赛 (黑龙江省第三名, 入围全国决赛) **2023 & 2024** 省优秀毕业生, 研究生特等奖学金 (连续两年)

学生工作

2023-2024 2019 级本科生第六党支部副书记

2025-至今 实验室师生联合党支部宣传委员

2024-至今 CCF 哈工大学生分会执委 · CCF 专业会员