

钱泽凯 Zekai Qian

博士在读 · 哈尔滨工业大学 · 海量数据计算研究中心

出生年月：2001 年 7 月 · 电话：13579810745 · 邮箱：qzk010728@gmail.com · 博士导师：王宏志 教授

研究方向：数据中心 AI (Data-centric AI) · 按需数据准备与数据清洗 · 面向大模型与机器学习的数据质量 · Agent 驱动的数据系统

🏠 主页：https://qzkinhit.github.io/ · 🎓 Google Scholar · 📝 OpenReview · 🐙 GitHub: qzkinhit



教育背景

2023–至今 哈尔滨工业大学 · 计算机科学 · 硕博连读（博士三年级在读，预计 2028 年毕业） 海量数据计算研究中心

2019–2023 哈尔滨工业大学 · 计算机科学 · 学士

代表性论文

面向模型的按需数据准备

ICML 2026 **CCF A** **学生一作** DMCO: Budget-Aware Co-Optimization of Data Cleaning and AutoML | X. Ding (副导师), **Z. Qian**, S. Chen, H. Hu, C. Wang, H. Wang, J. Wang

VLDB Workshop 2026 **Oral Paper Award** **一作** DemandPrep: Demand-Driven Data Preparation via Agentic Action Allocation and Operator-Grounded Execution | **Z. Qian**, X. Ding, H. Wang, C. Wang

VLDB 2025 **CCF A** **一作** DemandClean: A Multi-Objective Learning Framework for Balancing Model Tolerance to Data Authenticity and Diversity | **Z. Qian**, X. Ding, C. Wang, H. Wang

大规模、多模态数据质量管理体系与流水线（电网，华为云企业落地）

VLDB 2025 **CCF A** **Oral** **学生一作** UniClean: A Scalable Data Cleaning Solution for Mixed Errors based on Unified Cleaners and Optimized Cleaning Workflow | X. Ding (副导师), **Z. Qian**, H. Wang, S. Chen, Y. Tang, H. Su, H. Hu, C. Wang

ICDE 2025 **CCF A** **学生一作** UniClean: A Multi-Signal Fusion Pipeline for Optimizing Data Cleaning Workflow | X. Ding (副导师), **Z. Qian**, H. Wang, Z. Sun, S. Chen, H. Su, H. Hu

计算机科学 2024 **CCF B** **一作** **封面文章** 面向多样化数据清洗任务的证据集智能选择方法 (Evidence Set Selection for Diverse Data Cleaning Tasks) | **Z. Qian**, X. Ding, Z. Sun, H. Wang, Y. Zhang

ICDE 2025 **CCF A** CBAClean: A Comprehensive System for Recommending Data Cleaning Solutions Through Cost-Benefit Analysis in Data Quality Management | X. Ding (副导师), H. Su, **Z. Qian**, W. Cui, S. Chen, Z. Liang, C. Wang, H. Wang

ICDE 2025 **CCF A** tDCDiscover: Mining Threshold Denial Constraints from Time Series Data | X. Ding, M. Zhou, Y. Liu, **Z. Qian**, C. Wang, H. Wang, J. Wang

数据资产评估与治理（综述）

BDMA 2025 **SCI Q1** A Survey on Data Asset Value Change Estimation and Appreciation with Data Governance | X. Ding, G. Li, Y. Tang, C. Liang, T. Yu, M. Zhou, Y. Liu, **Z. Qian**, Z. Song, et al.

在投论文

VLDB 2027 在投 **CCF A** **一作** DemandClean: Task-Driven Operation Selection for Data Cleaning with Constrained Ground-Truth | **Z. Qian**, X. Ding, Z. Zhao, S. Chen, C. Wang, H. Wang

AAAI 2027 在投 **CCF A** **一作** OmniSelect: Adaptive Data Selection with Complementary Quality Signals for Modality-Specific Foundation Models | **Z. Qian**, X. Ding, Y. Tang, S. Cheng, C. Zhao, H. Wang, C. Wang

项目经历

2023–2025 **课题负责人** **华为云合作项目** 大数据质量提升流水线

面向生产数据多类错误混杂、亿级规模数据质量管理困难的问题，构建基于算子关联分块、核心集抽取与贡献溯源迭代编排的端到端自动清洗流水线，为下游分析与模型训练提供可扩展、自动化、可解释的高质量数据底座；

F1 较 SOTA 系统平均提升 20%，支撑华为云亿级生产数据小时级清洗（千万行 < 1 小时，32 核 CPU 集群）；

产出：华为发明专利 1 项；系统部署于华为云 DLI 生产环境，完成亿级生产数据验证落地。

论文 UniClean：可扩展混合错误清洗（VLDB, Oral, 二作 · 学生一作）· UniClean：多信号融合流水线（ICDE 2025, 二作 · 学生一作）

2024–至今 **学生主要参与** **黑龙江省自然科学基金** 面向数据智能的大数据质量评估与提升关键技术研究

围绕“数据为模型服务”主线，研究任务驱动的数据质量评估与按需数据准备，将数据准备与下游任务（分类、回归、预测，及多模态基础模型训练数据的质量管理）的真实需求对齐；

技术路线：多目标学习平衡数据真实性与多样性 → 将操作选择建模为成本约束序贯决策、以强化学习 Dueling Double DQN 求解 → 用 Agent 自主编排数据准备动作与算子执行。

论文 DemandClean：多目标学习（VLDB, 一作）· DemandClean：任务驱动操作选择（VLDB 2027 在投, 一作）· DemandPrep：Agent 数据准备（VLDB Workshop 2026, Oral Paper Award, 一作）

2021–2024 **项目骨干** **国家重点研发计划** 工业时序数据高鲁棒查询处理技术“工业软件”重点专项, 2021YFB3300502

面向工业时序数据构建“画一检一修”质量技术栈（评估、多类型错误检测、多维修修复），为下游时序预测与异常检测模型提供高质量数据；研发部署 tDCDiscover 等算法，参与国家电网科技项目（分层重构神经网络的电力时序异常检测，落地国网治理工具）。

论文 证据集智能选择（CCF BigData 2023 最佳学生论文, 一作；《计算机科学》2024 封面文章）· tDCDiscover（ICDE 2025）

2025–2026 **学生骨干（排名第一）** **“十四五”国家级规划教材** 《大数据质量》—— 大数据新兴领域国家级规划教材，全领域仅十本

获奖情况

2022 第十五届全国大学生信息安全竞赛（作品赛）— 全国一等奖（队长，第一贡献），作品：基于 MAE 人脸隐私保护方法的身份认证系统

2023 CCF BigData 2023 最佳学生论文（第一作者，本届大会唯一） **2024** 《计算机科学》封面文章（2024 年 8 月, 51(8)）

2023 全国大学生计算机系统能力大赛（黑龙江省第三名，入围全国决赛） **2023 & 2024** 省优秀毕业生，研究生特等奖学金（连续两年）

学生工作

2023–2024 2019 级本科生第六党支部副书记 **2025–至今** 实验室师生联合党支部宣传委员

2024–至今 CCF 哈工大学生分会执委 · CCF 专业会员